Neuronale Netze

Vorlesung Künstliche Intelligenz

Ulrike Pado

Themen heute

- Künstliche neuronale Netze (kNNs) und Deep Learning
- Einfachste Netze: Das einschichtige Perzeptron
- Realistische Beispiele: Verwendung von kNNs in der Praxis

Künstliche neuronale Netze

Orientierung an biologischen Strukturen: Auf der Suche nach schneller, hochparalleler Verarbeitung wie im Gehirn

- Umsetzung abstrahiert biologisches Vorbild deutlich
- Trotzdem Verwendung u.a. in der Psycholinguistik, um menschliches Lernen anzunähern

Grundlegende Idee

- Alle Netze bestehen aus
  - Knoten (Neuronen)
  - Verbindungen (Synapsen) mit Gewichten
  - Netze haben mindestens Ein- und Ausgabeschicht
- Verarbeitung von Information durch Weitergabe von Neuron-Aktivierung entlang der Verbindungen

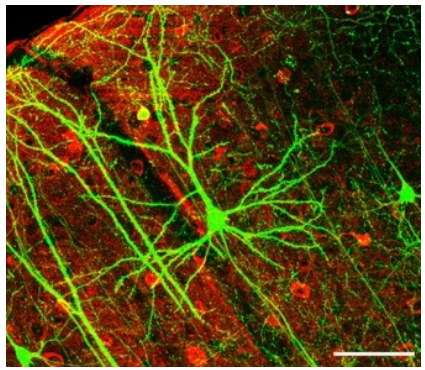
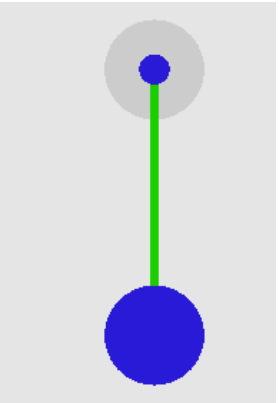


Bild: Lee et al., PLoS Biology Vol. 4, No. 2

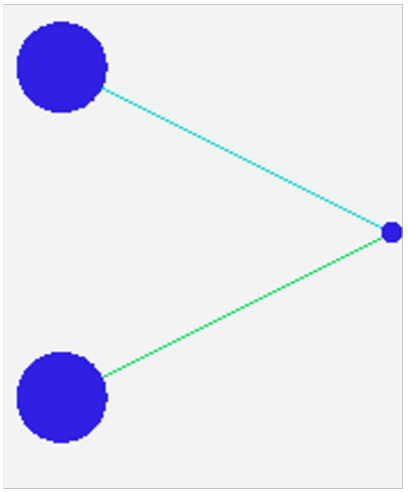


Künstliche Neuronale Netze: Historie

- Erste Ansätze: Entwicklung des Perzeptrons in den 60ern (Rosenblatt 1962); Einschränkung des Perzeptrons wird erkannt
- Mehrlagige Netze in den späten 80ern/frühen 90ern (Rumelhart, Hinton, Williams 1986)
- Rechenintensiv: Dornröschenschlaf ab Mitte der 90er
- Renaissance seit Hinton, Osindero und Teh (2006) als „Deep Learning“: Schnelle Algorithmen sind für große Datenmengen anwendbar

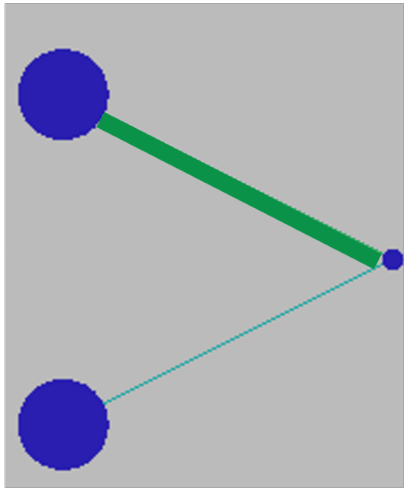
Einfache Netze: Perzeptrons

- Neuronen bilden Eingabe- und Ausgabeschicht, keine verborgenen Schichten
- Neuronen sind zwischen den Schichten vollständig vernetzt
- Gewichte der Verbindungen sind zunächst zufällig und werden während des Trainings angepasst



Aktivierung

- Die Aktivierung des einzelnen Neurons hängt von der Aktivierung über die Eingabeneuronen ab
- Die Input-Aktivierung wird über eine Aktivierungsfunktion (z.B. eine Sigmoid-Funktion) in die finale Aktivierung des Neurons übersetzt
- Analogie aus der Biologie: Ein gewisses Maß an Aktivierung muss gegeben sein, bevor ein Neuron feuert

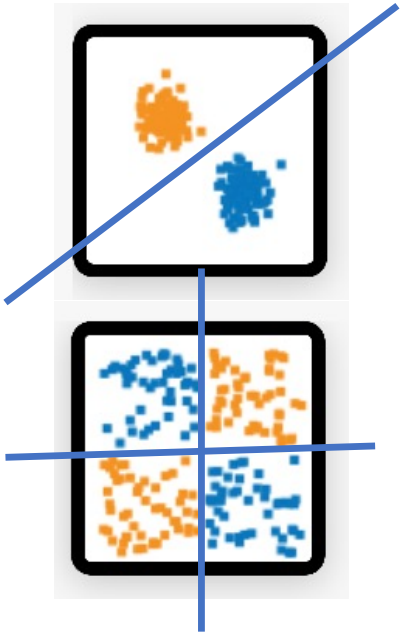


Interpretation der Ausgabe

Vor dem Hintergrund einer Klassifikationsaufgabe (Input gehört zu Klasse 1 oder nicht):

- Am Einfachsten: einziges Perzeptron-Ausgabeneuron feuert vs. feuert nicht
- Komplizierter: Mehrere Ausgabeneuronen feuern in einem bestimmten Muster
  - Beispiel: 4 Neuronen, aus-an-an-aus heißt „Klasse 1 liegt vor“

Einschränkung des Perzeptrons: Nicht linear separierbare Probleme



Mit einer einzigen Entscheidungslinie lösbar

Nicht mit einer einzigen Entscheidungslinie lösbar

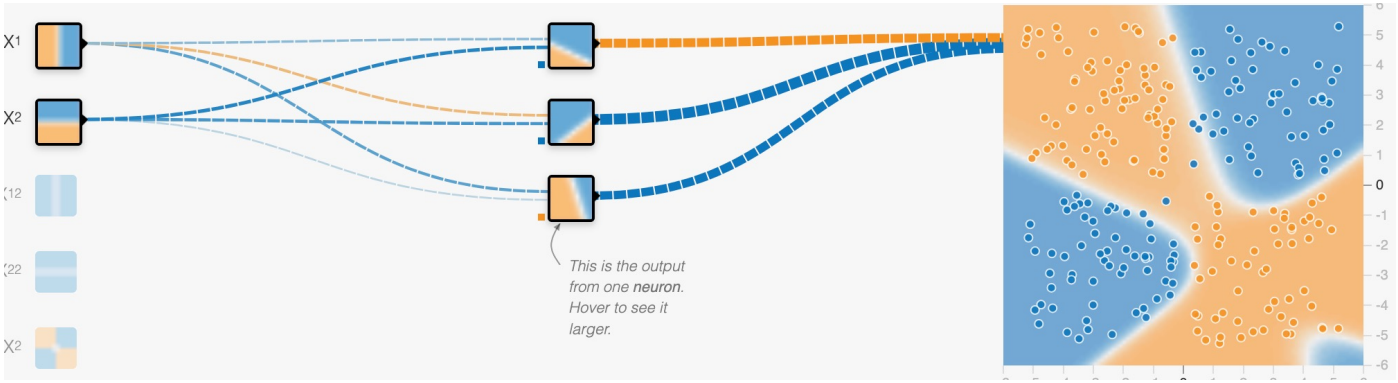
Linear separierbar (oder separabel) sind Klassifikationsprobleme, bei denen eine einzige Entscheidungslinie im Raum ausreicht, um die beiden Zielklassen klar zu trennen.

Nur diese Problemklasse beherrschen einschichtige Perzeptrons.

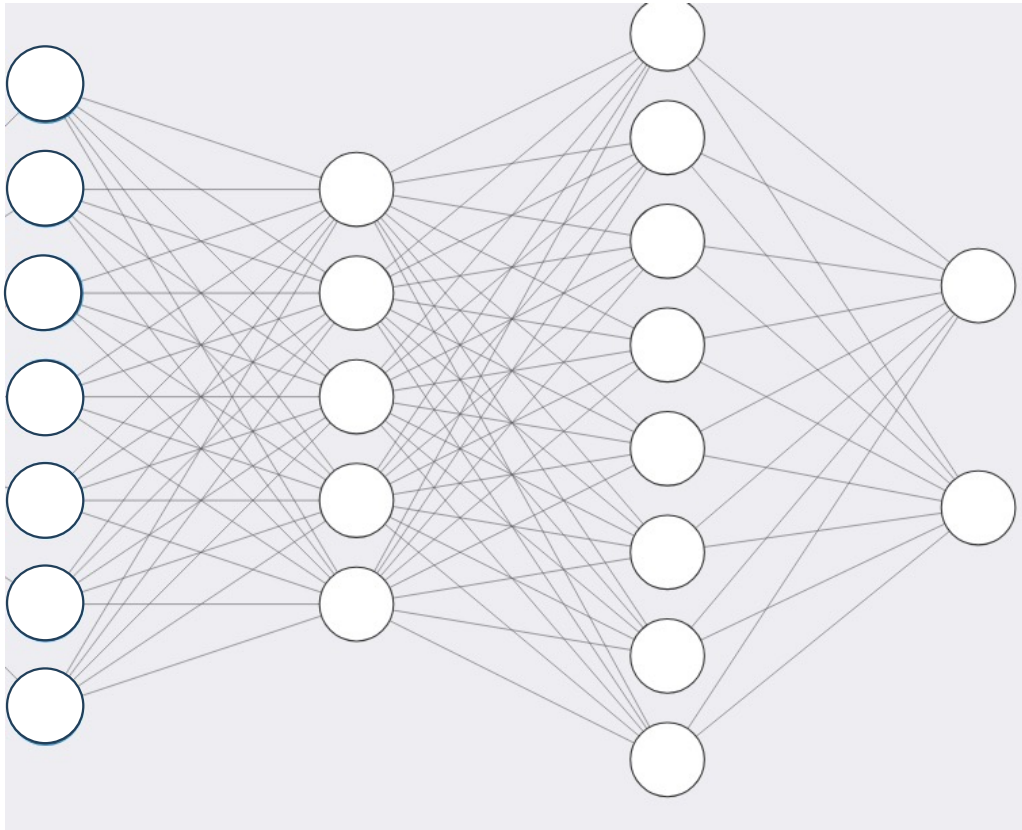
Abbildungen auf dieser und der folgenden Folie von https://playground.tensorflow.org

Erweiterung des Perzeptrons

- Realistische Netzwerkarchitekturen bestehen aus vielen Neuronenschichten
- Jede weitere Schicht erweitert die Lernfähigkeit des Netzwerks
- Mehrschichtige Perzeptrons lösen auch linear separable Probleme



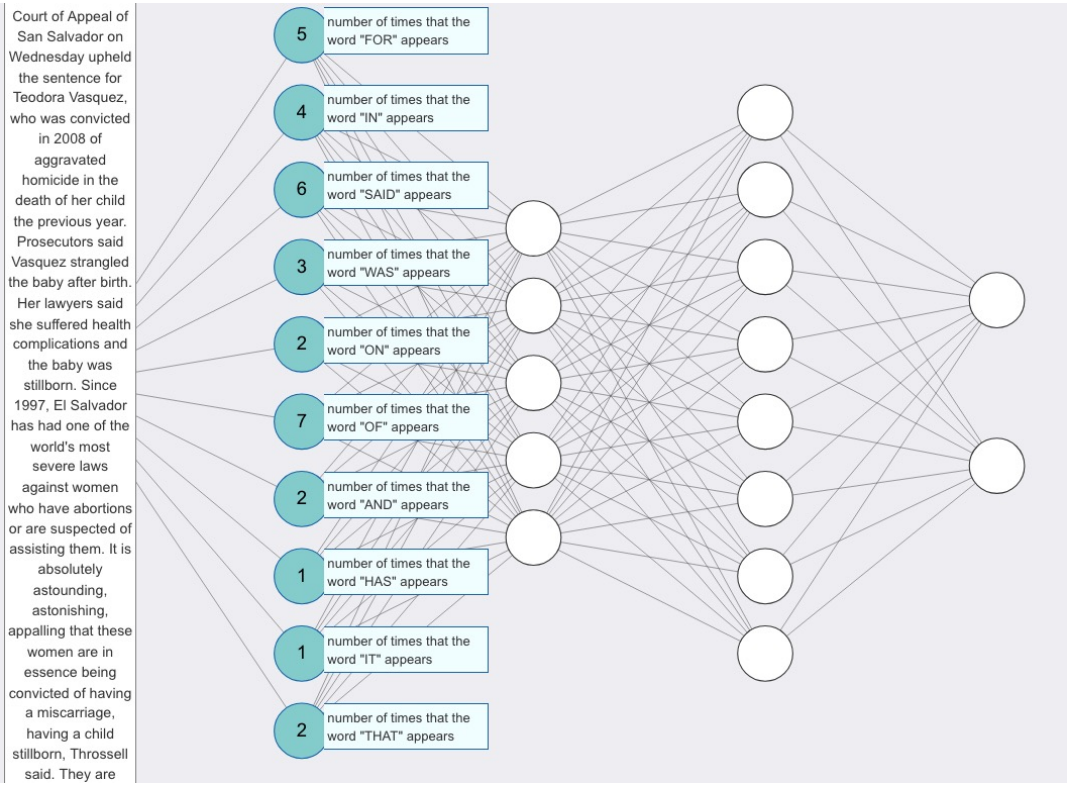
Einfaches Beispiel: Neuronales Netz zur Textklassifikation



- Eingabeschicht (ganz links) erhält Textrepräsentation als Eingabeaktivierung
- Aktivierung der folgenden Schichten wird aus den Eingabeaktivierungen der Vorgängerschicht, den Verbindungsgewichten und der Aktivierungsfunktion berechnet
- Aktivierung der Ausgabeschicht (ganz rechts) wird als Klassifikations-entscheidung interpretiert

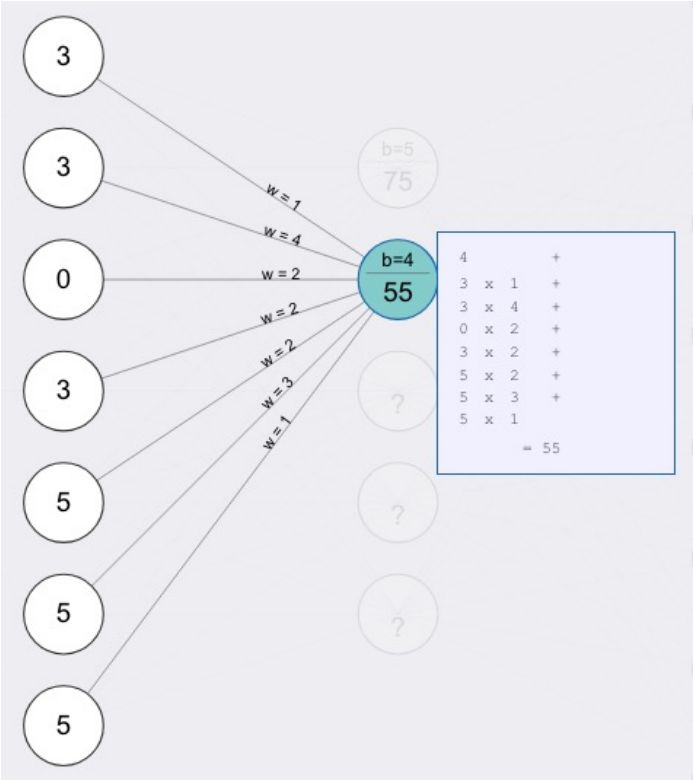
Abbildung auf dieser und den folgenden Folien von www.machinelearningforkids.co.uk

Neuronales Netz zur Textklassifikation: Eingaberepräsentation



- Textrepräsentation für die Eingabeschicht: Vektor von Worthäufigkeiten

Neuronales Netz zur Textklassifikation: Aktivierung

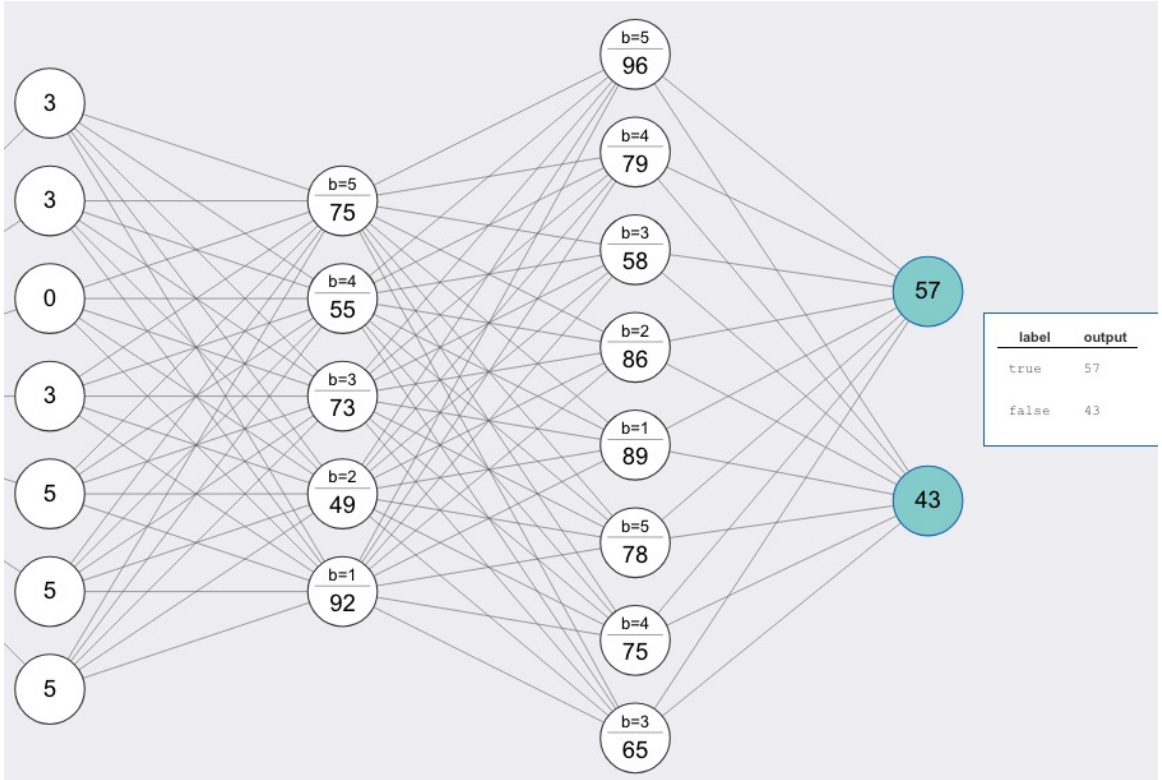


Aktivierung der folgenden Schichten wird aus

- Einem Knotenbias b (ähnlich einer Voraktivierung),
- den Eingabeaktivierungen der Vorgängerschicht,
- den Verbindungsgewichten und
- der Aktivierungsfunktion (hier linear: x1)

berechnet

Neuronales Netz zur Textklassifikation: Ausgabe



Interpretation der Ausgabe:
Hier: Stärker aktivierter Knoten “zählt“

Lernen mit Neuronalen Netzwerken

- Lernen bedeutet, die Verbindungsgewichte und ggf. Biases so anzupassen, dass für jeden Input die korrekte Aktivierung in der letzten Netzwerkschicht generiert wird

- Strategie des Gradient Descent: Abstieg auf der unebenen Fehlerfläche, möglicherweise in ein lokales Optimum (Gradient Descent-Demo)

- Steuerung der Lerngeschwindigkeit u.a. durch die Learning Rate

Bedeutung von Neuronalen Netzwerken

- Sehr flexibler und mächtiger Lernalgorithmus
- Quasi-Standard für viele Anwendungen (Bildverarbeitung, Verstehen gesprochener Sprache, maschinelle Übersetzung)
- Intensive Forschung an der Interpretierbarkeit