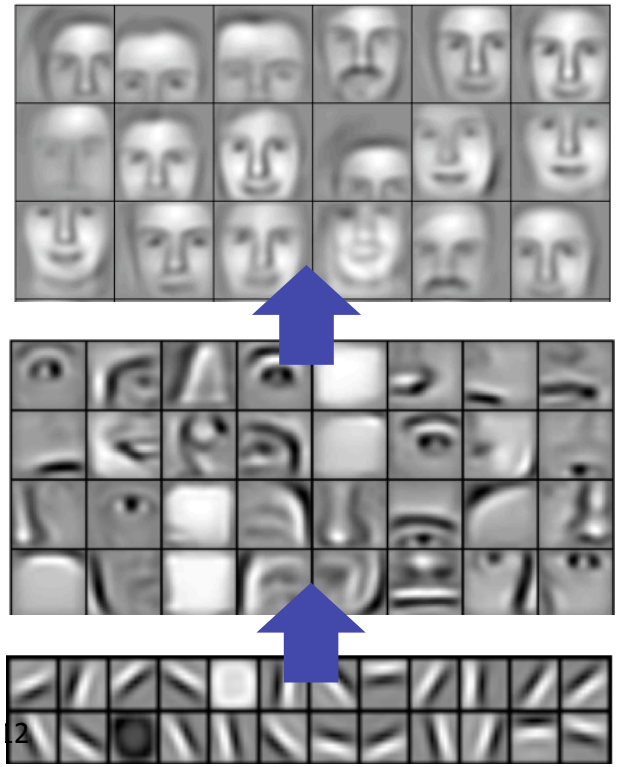
Neuronale Netze

Vorlesung Künstliche Intelligenz

Ulrike Pado

Anwendung 1: Objekterkennung
(Lee et al., ICML 2009)

- Repräsentation der Lernergebnisse verschiedener Schichten bei der Objekterkennung
- Schicht 1 lernt, Kanten zu erkennen
- Schicht 2 erkennt Teilareale
- Schicht 3 repräsentiert das ganze Gesicht



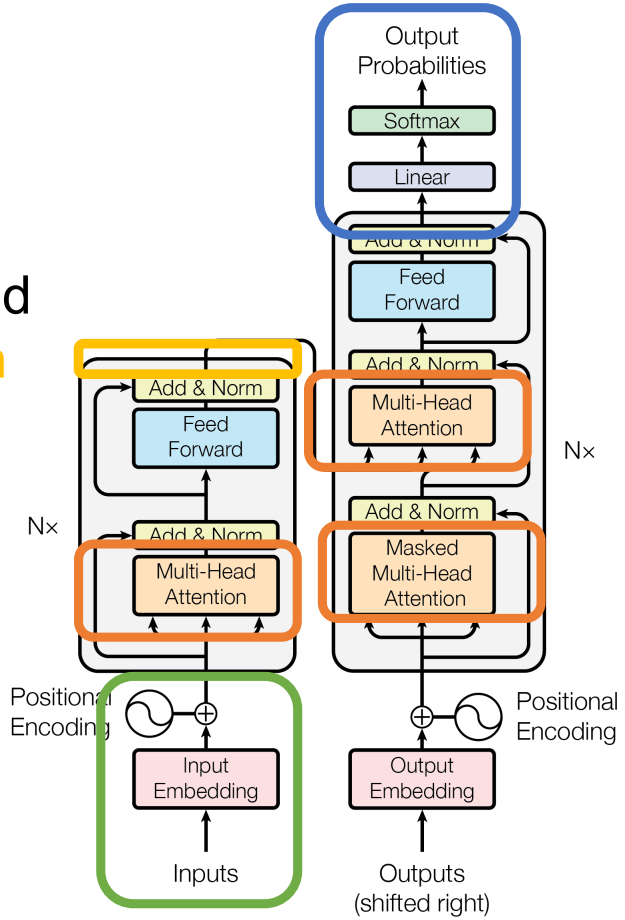
Anwendung 2: Gesprochene Sprache verstehen

- Keine leichte Aufgabe (vgl. Telefonieren in einer Fremdsprache)
- Probleme: Tonqualität, Akzente/Dialekte, freier Wortschatz
- Seit 2017 sind neuronale Netze besser als menschliche Transkriptoren... (Xiong et al., IEEE ICASSP 2018)
- Wichtig: Rekurrente Netzwerke, die die Reihenfolge der Eingabesignale berücksichtigen und sich an zurückliegende Signale „erinnern“: Kontext!

Anwendung 3: Übersetzung

- Hochkomplexe neuronale Netze codieren den Input und übersetzen ihn in eine abstrakte innere Repräsentation (zusammen: Encoder)
- Die innere Repräsentation wird dann wieder in den gewünschten Output zurückverwandelt (Decoder)
- Beides zusammen heißt Transformer (und verwandelt z.B. Deutsch nach Englisch)
- Wichtige Neuerung: Attention. Das Netzwerk kann je nach Kontext die Teile des Inputs höher gewichten.

- Der Eingabetext wird als Embeddings repräsentiert – das ist eine von Netzwerken gelernte Repräsentation auf Basis der Verteilung von Wörtern in Texten



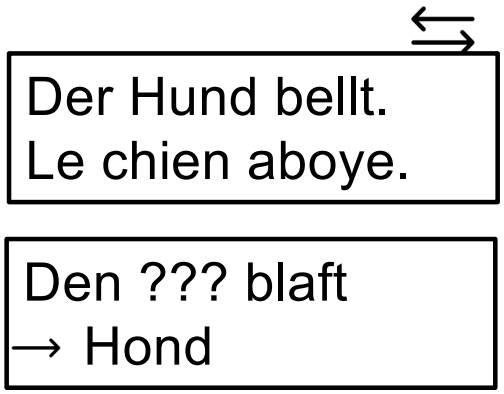
Transformer-Architektur (Vaswani et al 2017)

Seltene Sprachen übersetzen

(Bapna et al. 2022, Google White Paper)

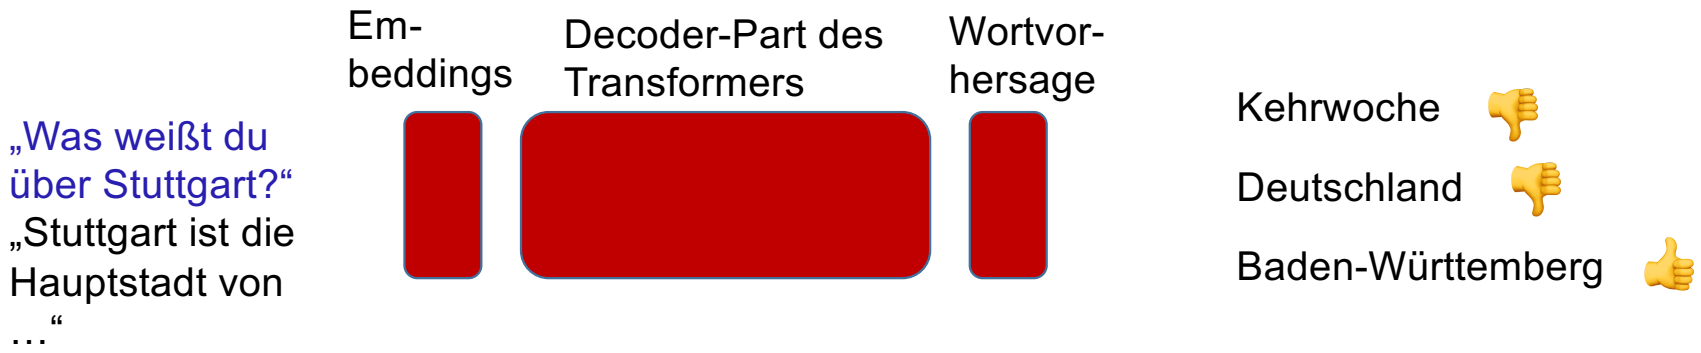
- Schritt 1: Transformer für Übersetzungen zwischen (112) häufigen Sprachen trainieren
  -> überwachtes Lernen, Lösung bekannt, gute Ergebnisse
- Schritt 2: Diesen Transformer weitertrainieren: Aufgabe jetzt Wortvorhersage für 200 seltenere Sprachen

- Übersetzung wird für diese 200 Sprachen noch besser, wenn man mit weiteren 800 seltenen Sprachen weitertrainiert; Übersetzung ist nun **zwischen allen 1000** Sprachen möglich
- Fazit: Die innere Repräsentation des Modells profitiert von jeder Art von Input, ist sprachunabhängig



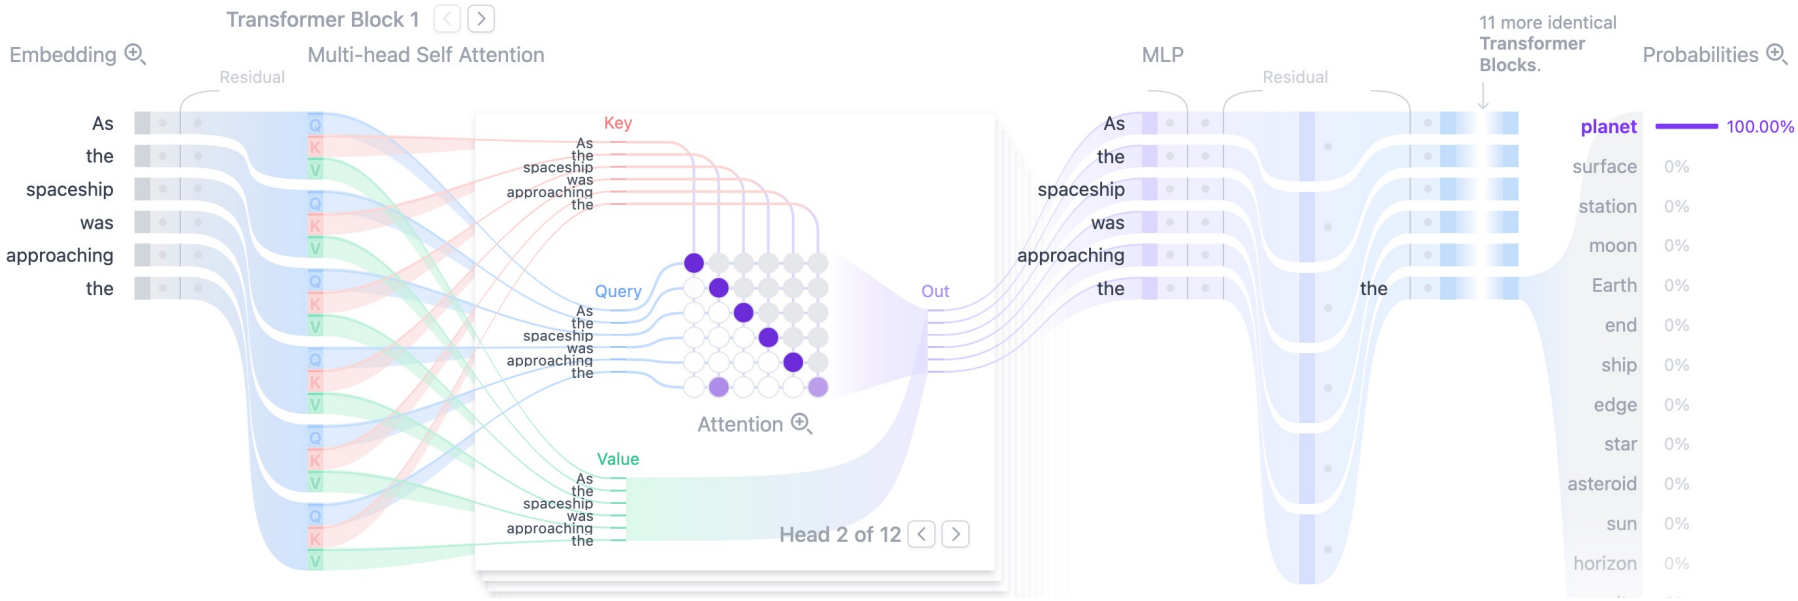
Anwendung 4: Sprachmodelle auf Transformer-Basis

(OpenAI 2023, White Paper)



- Grundlage der GPT-Modelle
- … und Llama, DeepSeek, …

Oder mit mehr Detail: Transformer-Explainer https://poloclub.github.io/transformer-explainer/



Embeddings

Decoder-Part des Transformers

Wortvorhersage

Vorteile von Neuronalen Netzwerken

- Großer Unterschied zu früheren Ansätzen: Merkmale müssen nicht (stark) aufbereitet werden
  - Bilder werden als Pixel repräsentiert
    - ➢ 1 bis 3 Eingabeknoten pro Pixel (b-w oder rgb)
  - Texte werden als (Unter-)Zeichenketten repräsentiert
    - ➢ Embeddings
- Große Fähigkeit der Modelle, Muster aus den Eingabedaten eigenständig zu erkennen

Nachteile von Neuronalen Netzen

- Hoher Bedarf an Trainingsdaten
- Starke Abhängigkeit des Ergebnisses von optimaler Parametrisierung (initiale Gewichte, Trainingsgeschwindigkeit, ...)
- Hoher Bedarf an Rechenkapazität
- Noch „black box“; schlechte Interpretierbarkeit

Neuronale Netze

- Mächtiger Algorithmus
- Mächtiger Bedarf an Trainingsdaten, Parameteroptimierung und Rechenzeit...
  - Mittlerweile vorfabriziert und vortrainiert verfügbar
- Schwer zu interpretieren
- Faszinierende Technologie für Forschung und Produktion!

Literatur

- Alpaydin, Maschinelles Lernen, de Gruyter/Oldenbourg, 2008.
- Mitchell, Machine Learning, McGraw-Hill, 1997.