Maschinelles Lernen

Vorlesung Künstliche Intelligenz

Ulrike Pado

Übersicht

- Was ist Maschinelles Lernen?
- Wie können Daten aussehen?
- Was kann man mit ihnen machen?

Rückblick: Was ist I?

Intelligenz: „the ability to perceive or infer information, and to retain it as knowledge to be applied towards adaptive behaviors“ (Wikipedia, 2021)

- perceive: sehen, hören, Sprache verstehen
- infer: logisches Schließen, Schließen unter Unsicherheit
- retain: lernen
- knowledge: Wissensrepräsentationen
- to be applied: selbstgesteuertes Verhalten
- adaptive behavior: angemessene Reaktion auf neue Situationen, dabei Umsetzen der eigenen Ziele

Was ist Maschinelles Lernen?

Eine Maschine lernt an Beispielen, eine Aufgabe selbständig auszuführen.

Die Aufgabe:

- Daten klassifizieren (z.B. Junk-Mail-Filter)
- Zahlenwerte vorhersagen (z.B. Börsenkurse)

Was ist Maschinelles Lernen?

Eine Maschine lernt an Beispielen, eine Aufgabe selbständig auszuführen.

Die Aufgabe: Daten klassifizieren

- Beispieldaten werden gegeben
- Datenpunkte haben Attribute und eine Zielklasse
- Computer sucht Regelmäßigkeiten: Wann wird ein Datenpunkt einer Klasse zugeordnet?
- Anhand der erkannten Regelmäßigkeiten können neue Datenpunkte einsortiert werden

Die Ursprungsdaten

Woher kommen sie?

- Selbst erhoben: Firmenintern oder Kundendaten
- Von einem Datenlieferanten
- ... freie Datensätze zum Lernen und Testen

Sind sie vollständig oder eine Auswahl?

- Unvollständige Datensätze spiegeln die Wirklichkeit u.U. verzerrt wieder

Ein Datensatz

- Format: Üblicherweise CSV oder Datenbank (leider oft auch Excel)
- Jede Zeile ein Datenpunkt
- Datenpunkte haben möglicherweise eine ID
- Datenpunkte haben Merkmale (Features, Attribute)
- Datenpunkte haben möglicherweise eine Zielklasse (meist nicht besonders gekennzeichnet)
- Bedeutung der Merkmale und die Zielklasse erschließen sich meist nur aus Zusatzinformation

Ein Datensatz

Relation: Speed Dating

76: exercise	77: dining	78: museums	79: art	80: hiking	81: gaming	82: clubbing	83: reading	84: tv	85: theater	86: movies	87: concerts	88: music	89: shopping
Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
7.0	10.0	8.0	6.0	3.0	5.0	8.0	10.0	1.0	9.0	8.0	7.0	8.0	3.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	10.0	5.0	5.0	6.0	7.0	9.0	8.0	1.0	1.0	7.0	7.0	7.0	7.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0
10.0	9.0	6.0	6.0	10.0	6.0	3.0	6.0	1.0	6.0	9.0	8.0	8.0	6.0

Aufgabe: Speed Dating

- Wir werden diese Woche mit einem frei verfügbaren Datensatz arbeiten (s. Moodle).
- Schauen Sie sich die Datei speeddating info an und finden Sie so viel wie möglich über die Daten heraus.
- Beantworten Sie die Fragen im Moodle-Test.

Maschinelles Lernen

Vorlesung Künstliche Intelligenz

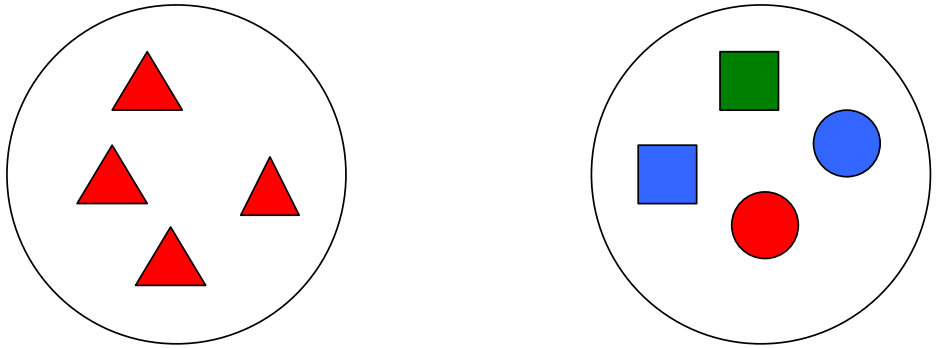
Ulrike Pado

Übersicht

- Was ist Maschinelles Lernen?
- Wie können Daten aussehen?
- Was kann man mit ihnen machen?
  - Klassifikation
  - Evaluation

Klassifikation

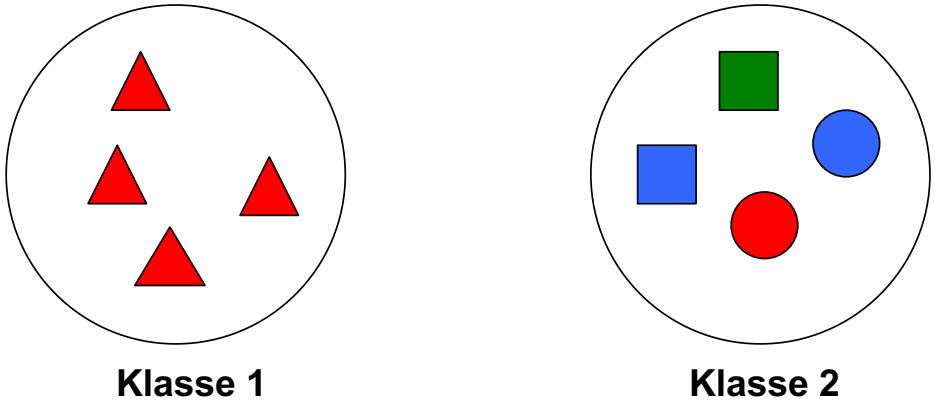
- Instanzen sollen Klassen zugeordnet werden



Klasse 1 **Klasse 2**

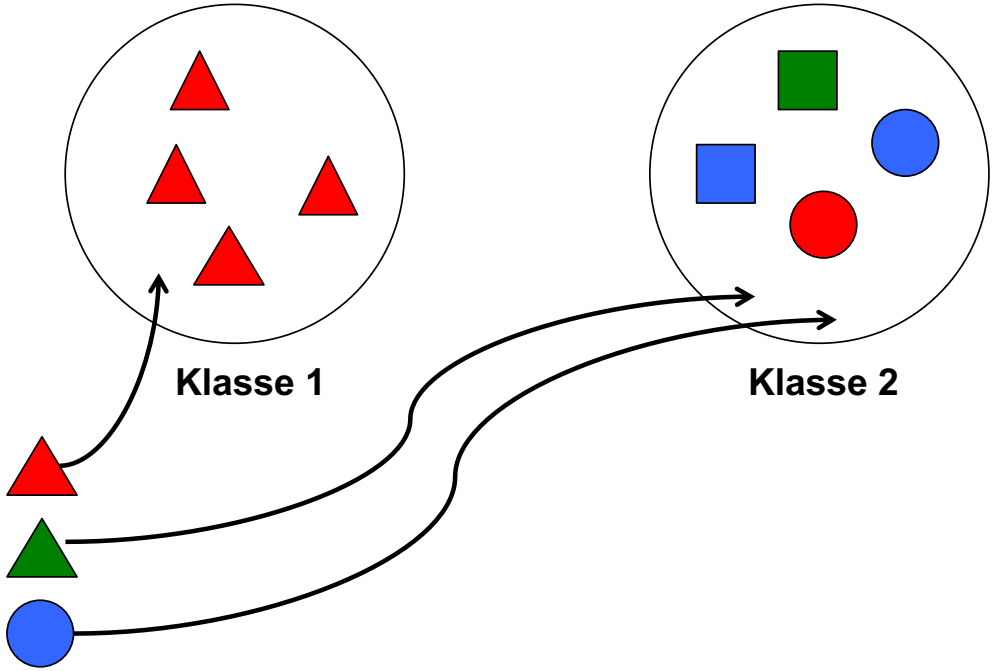
- Instanzen haben Merkmale, die die Zuordnung ermöglichen
  - Farbe: rot, grün, blau
  - Form: Dreieck, Kreis, Quadrat

Einfache Klassifikationsregel



- Betrachten der Instanzen in den beiden Klassen: Gibt es Regelmäßigkeiten?
- einfache Regel: rote Dreiecke gehören in Klasse 1, alle anderen Formen in Klasse 2

Klassifikation neuer Instanzen



- Regel anwenden: rote Dreiecke gehören in Klasse 1, alle anderen Formen in Klasse 2

Lernalgorithmen

- Das Erstellen und Anwenden der Klassifikationsregeln übernehmen Lernalgorithmen
- Unsere Aufgabe ist das Bereitstellen von ausreichend Trainingsdaten mit informativen Attributen

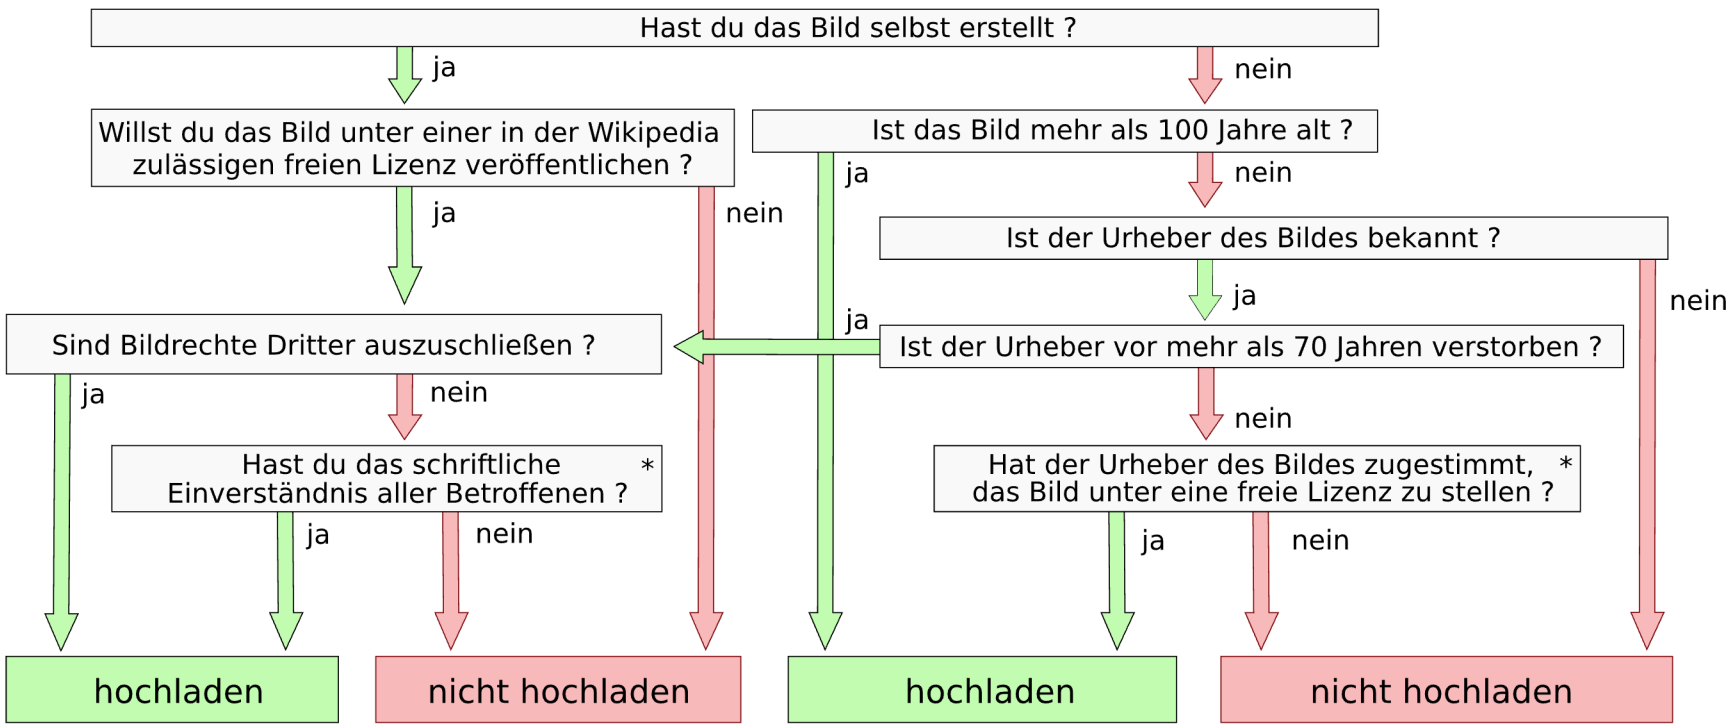
Auswahl des Algorithmus

- Das Erstellen und Anwenden der Klassifikationsregeln übernehmen Lernalgorithmen
- Unsere Aufgabe ist das Bereitstellen von ausreichend Trainingsdaten, die informativ sind
  - Alle Zielklassen hinreichend oft vertreten
  - Instanzen hinreichend unterschiedlich
  - Je komplexer der Lernalgorithmus, desto mehr Datenbedarf
- Hype-Algorithmen sind nicht immer die beste Wahl
  - Meist sehr komplex: Datenbedarf, hoher Rechenaufwand
  - Konkret: Deep Learning braucht viele Daten, trainiert auf GPUs und ist schwer zu interpretieren

Unser Beispiel: Entscheidungsbäume

- An jedem Knoten wird eine Frage gestellt
- Je nach Antwort geht es mit einem der Zweige weiter
- Die Blätter stellen das jeweilige Klassifikationsergebnis dar

Entscheidungsbaum: Bild-Upload in Wikipedia



* Sämtliche Anfragen an den Rechteinhaber sind an das OTRS (permission-de@wikimedia.org) weiterzuleiten.

Von odder - own work, based on png version originally uploaded to the Commons by San Jose, Gemeinfrei, https://commons.wikimedia.org/w/index.php?curid=1910571

Gelernte Entscheidungsbäume

- Entscheidungsbaum allgemein: vom Experten erstellt, um Entscheidungen zu veranschaulichen (s.o.)
- Entscheidungsbaum im ML: auf Basis der Trainingsdaten erstellt, um für Testdaten Voraussagen zu machen

- Suchen Merkmale und Merkmalskombinationen, die besonders schnell zu einer Klassifikationsaussage führen
- Gelernter Baum wird zur Klassifikation neuer Instanzen eingesetzt
- Baum ist vom Menschen interpretierbar: Entscheidung kann erklärt werden, Datenmuster werden klar

Demo: Entscheidungsbaum in Python

Maschinelles Lernen

Vorlesung Künstliche Intelligenz

Ulrike Pado

Übersicht

- Was ist Maschinelles Lernen?
- Wie können Daten aussehen?
- Was kann man mit ihnen machen?
  - Klassifikation
  - Evaluation

Wie testen?

- Modell ist trainiert, kann verwendet werden
- Aber: Wie gut ist es?

- Wir brauchen Testdaten - hier kennen wir die Zielklassen
  - Vergleich Vorhersage – echter Wert möglich

Warum separate Testdaten?

- Nehmen wir doch das Trainingsset!
  - Trainingsset ist groß
  - Klassen sind bekannt

- Probleme:
  - Trainingsinstanzen sind alle schon gesehen: Hohe WK, dass man sie richtig macht
  - Der Ernstfall wird anders aussehen!

Testdaten erstellen

- Ursprungsdatensatz wird vor dem ersten Training geteilt, z.B. 90%-10% oder 66%-33%

- Daten sind im Training ungesehen – genau wie unsere zu klassifizierenden Daten später im produktiven Einsatz
- Trainings- und Testdaten sind sich sehr ähnlich: fairer Test
- Trainingsdatensatz wird kleiner!

Entwicklungsdaten erstellen

- Wenn wir bei der Entwicklung unseres Modells verschiedene Varianten vergleichen wollen (neue Attribute, verschiedene Lernalgorithmen, verschiedene Parameter der Algorithmen), brauchen wir Testdaten zum Vergleich
- Die reservierten Testdaten dürfen wir nicht nehmen: Sonst sind sie ja nicht mehr ungesehen…

- Ursprungsdatensatz vor dem ersten Training in drei Teile teilen: z.B. 80%-10%-10% oder 60%-20%-20%
- Achtung: Die Entwicklungs- und Testanteile müssen so groß sein, dass man sinnvolle Aussagen ableiten kann (daher: je größer der Datensatz, desto kleiner die Entwicklungs- und Testanteile)

Gelerntes Modell evaluieren

- Standardmaße: Precision, Recall, F-Wert
  - Precision und Recall werden immer aus Sicht einer bestimmten Zielklasse berechnet
  - Beschreiben unterschiedliche Eigenschaften der Vorhersage
  - F-Wert kombiniert beide in eine Zahl: $\frac{2 \cdot P \cdot R}{P + R}$
- Um die Gesamtperformanz über alle Klassen zu beschreiben, können P, R, F gemittelt werden

Precision und Recall

- Precision: Wie verlässlich ist die Vorhersage von Klasse A?
  - Wenn ich 100x Klasse A vorhergesagt habe, wie oft hat es gestimmt?
  - 90x: Vorhersage ist sehr zuverlässig
  - 20x: Hände weg...

- Recall: Wie viele Instanzen wurden wirklich gefunden?
  - Wenn ich 100 Instanzen von Klasse A in den Testdaten hatte, wie viele wurden gefunden?
  - 90: Fast alle erwischt, prima!
  - 20: Zu viel verpasst

Precision und Recall: Beispiel

- Ihre Beratungsfirma hat ein Projekt mit einem Sicherheitsdienst. Es sollen per Videoüberwachung verdächtige Personen identifiziert werden.

- Recall der Klasse „verdächtig“ ist 90%! Ihnen entwischt quasi niemand.
- Precision ist aber nur 10%... 9 von 10 Alarmen sind falsch. Alle sind genervt.

Precision und Recall: Beispiel II

- Sie trainieren einen Spamfilter für Ihre Emails.

- Precision der Klasse „kein Spam“ ist 90%! Nie wieder Müll ☺
- Recall ist aber nur 60%... Schon drei lukrative Jobangebote verpasst **und** die Erbtante verärgert!

Testen und Entwickeln

Ablauf:

- Modell trainieren
- Modell testen (auf den Entwicklungsdaten)
- Fehleranalyse
- Modell verbessern (neue Attribute, ...)
- wieder von vorn...

Am Schluss:

- Modell testen (auf den ungesehenen Testdaten)
- Ergebnis als Precision, Recall, F-Wert berichten

Demo: Entscheidungsbaum in Weka testen